Hausaufgabe: RAG-System für Netzwerkadministration implementieren

1. Aufgabenstellung

Sie sind als **Junior Netzwerkadministrator** in einem mittelständischen Unternehmen (300 Mitarbeiter, IT-Dienstleister) tätig. Ihr Teamleiter **Alexander Vogel** hat über die Jahre umfangreiche **Administrations-Skripte, Checklisten und Dokumentation** erstellt. Diese liegen als Textdateien, Markdown-Dokumente und PDFs vor.

Die Geschäftsführung möchte ein **internes KI-Wissenssystem** einführen, mit dem neue Mitarbeiter selbstständig auf Alexanders Dokumentation zugreifen und Fragen zu Netzwerkthemen stellen können.

Ihre Aufgabe:

1. Richten Sie ein **RAG-System mit Open WebUI** ein (lokal auf Ihrem Windows-11-Rechner).
2. Integrieren Sie die **Skripte und Dokumentationen von Alexander Vogel** in eine **Knowledge Base**.
3. Testen Sie das System mit **mindestens 10 sinnvollen Prompts** aus verschiedenen Netzwerk-Administrationsszenarien.
4. Dokumentieren Sie Ihre Ergebnisse und reflektieren Sie die Qualität der Antworten.

2. Bereitgestellte Dokumente (Skripte von Alexander Vogel)

Sie erhalten folgende fiktive Administrations-Dokumente (als PDF/TXT/Markdown/PowerShell):

Dokument	Inhalt
`Vogel_Netzwerk_Skript.pdf`	Skript für Netzwerk-Migrationen, VLAN-Konfiguration, IP-Planung

Technische Voraussetzungen

Mindestanforderungen:

- Python 3.10 oder höher installiert
- LM Studio installiert und ein LLM geladen (z. B. Llama 3.1 8B, Mistral, CodeLlama)
- Open WebUI in virtueller Umgebung installiert
- PostgreSQL mit pgvector (lokal oder Docker-Container)

Alternativ: SQLite + ChromaDB (nur für Testzwecke, nicht produktionsgeeignet)

4. Schritt-für-Schritt-Anleitung

Schritt 1: Open WebUI mit RAG-Unterstützung starten

Erstellen Sie ein PowerShell-Skript (`start-rag.ps1`), das Open WebUI mit folgender Konfiguration startet:

- **Datenbank:** PostgreSQL mit pgvector (oder SQLite + ChromaDB als Alternative)

- **LM Studio:** API-Server auf `http://localhost:1234/v1`
- **RAG-Einstellungen:** `RAG_TOP_K=5`, `RAG_RELEVANCE_THRESHOLD=0.7`

Hinweis: Dokumentieren Sie Ihr Start-Skript im Abgabe-PDF (Code-Snippet einfügen).

Schritt 2: Knowledge Base erstellen

1. Melden Sie sich als **Admin** in Open WebUI an (erster Benutzer).
2. Erstellen Sie eine **neue Collection** namens „Alexander Vogel – Netzwerk-Dokumentation".
3. Laden Sie **alle 5 bereitgestellten Dokumente** hoch.
4. Warten Sie, bis alle Dokumente den Status **„Ready"** haben (Indizierung abgeschlossen).

Dokumentation: Fügen Sie einen Screenshot des Knowledge-Panels mit allen 5 Dokumenten ein.

Schritt 3: Prompts testen und protokollieren

Stellen Sie **mindestens 10 verschiedene Prompts** aus den folgenden Kategorien:

Kategorie	Beispiele
Firewall & Security	„Welche Ports müssen für RDP-Access freigeschaltet werden?"
VPN-Konfiguration	„Wie richte ich eine Site-to-Site-VPN mit WireGuard ein?"

Für jeden Prompt dokumentieren Sie:

1. **Den genauen Prompt** (Wort für Wort)
2. **Die Antwort von Open WebUI** (vollständiger Text)
3. **Die angezeigten Quellen** (welches Dokument, welcher Abschnitt)
4. **Ihre Bewertung** (1–5 Sterne):
    - War die Antwort technisch korrekt?
    - Waren die Quellenangaben hilfreich?
    - Würden Sie die Antwort einem Kollegen im NOC weitergeben?

Beispiel-Protokoll:

```
Prompt #1: „Welche Firewall-Regeln brauche ich für RDP-Zugriff von extern?"

Antwort:
„Laut Firewall-Dokumentation von Alexander Vogel müssen folgende Regeln
konfiguriert werden:
1. TCP Port 3389 inbound von vertrauenswürdigen IPs
2. NLA (Network Level Authentication) aktivieren
3. RDP-Gateway für externe Zugriffe verwenden
4. Logging aller RDP-Sessions aktivieren

Wichtig: Direkter RDP-Zugriff aus dem Internet ist untersagt (Security Policy
2.3)."

Quellen:
- Vogel_Firewall_Regeln_Dokumentation.md, Abschnitt 4.2 [cite:knowledge:1]

Bewertung: ⭐⭐⭐⭐⭐ (5/5)
- Antwort technisch korrekt und vollständig
- Quellenangabe eindeutig
- Security-Hinweis wertvoll
- Würde ich im NOC weitergeben
```

Schritt 4: RAG-Einstellungen optimieren (Bonus-Aufgabe)

Testen Sie **zwei verschiedene Konfigurationen** und vergleichen Sie die Ergebnisse:

Variante A: `RAG_TOP_K = 3`, `RAG_RELEVANCE_THRESHOLD = 0.8`
Variante B: `RAG_TOP_K = 10`, `RAG_RELEVANCE_THRESHOLD = 0.5`

Fragen zur Reflexion:

- Welche Variante liefert technisch präzisere Antworten?
- Welche Variante liefert mehr Kontext (z. B. vollständige Skripte)?
- Für welchen Use Case (Quick-Fix vs. Deep-Dive) würden Sie welche Einstellung empfehlen?

Dokumentieren Sie Ihre Erkenntnisse (ca. 100–200 Wörter).